

Assignment 1: Tokenization & POS Tagging (Chinese)

Date: 2026-03-12

Learning Objectives

- Perform sentence segmentation and tokenization on Chinese text
- Apply Part-of-Speech (POS) tagging
- Analyze token frequency and POS distributions

Note (說明) : Use **Chinese text** as your main material. You may use built-in samples below.

Allowed Libraries

- `re`, `collections`
- `jieba`, `jieba.posseg` (recommended for quick start)
- `spacy` with a Chinese model (optional)
- `stanza` (optional)

Submission Format: PDF (繳交格式)

- We need to assess your assignment by your code and the results. You can export a jupyter notebook with results as a PDF file, or you can summarize your code and results in other sc but eventually export as a PDF file.
- Remember: The file you submit should **contain your code and results**. (檔案必須為PDF檔可見你的程式碼以及執行結果)

Deadline: 繳交期限

- 2026/03/27 08:30
- You have two weeks to finish this work

0. Setup

```
In [1]: # 環境設定 (使用 uv 虛擬環境)
# !uv pip install jieba spacy
# !uv pip install zh-core-web-sm@https://github.com/explosion/spacy-models

import warnings
warnings.filterwarnings("ignore", category=SyntaxWarning)
```

1. Sample Data (Replace with your own if desired)

```
In [2]: SENTENCES_ZH = [
    "今天是個好天氣，我們一起去台北市立美術館吧！",
    "自然語言處理在教育、醫療與金融領域都有廣泛應用。",
    "請問下週三下午兩點在BS440教室還有課嗎？",
    "你覺得大型語言模型在中文任務上的表現如何？",
    "他知道這件事不要緊",
    "這份報告我寫不好",
    "他有一個女兒，在醫院工作",
    "我在樓上看到了他",
    "兒的生活好痛苦也沒有糧食多病少掙了很多錢"
]
```

2. Sentence Segmentation (句子切分)

```
In [3]: import re

def split_sentences(text: str):
    """Split Chinese text into sentences using punctuation heuristics."""
    parts = re.split(r"(?<=[。！？！？])", text)
    return [p.strip() for p in parts if p.strip()]

# TODO: Test your function on a paragraph of your own
for s in SENTENCES_ZH:
    print(split_sentences(s))
```

```
['今天是個好天氣，我們一起去台北市立美術館吧！']
['自然語言處理在教育、醫療與金融領域都有廣泛應用。']
['請問下週三下午兩點在BS440教室還有課嗎？']
['你覺得大型語言模型在中文任務上的表現如何？']
['他知道這件事不要緊']
['這份報告我寫不好']
['他有一個女兒，在醫院工作']
['我在樓上看到了他']
['兒的生活好痛苦也沒有糧食多病少掙了很多錢']
```

3. Tokenization (斷詞)

```
In [4]: import jieba

def tokenize_zh(text: str):
    return [tok for tok in jieba.lcut(text) if tok.strip()]

for s in SENTENCES_ZH:
    print(tokenize_zh(s))
```

```
Building prefix dict from the default dictionary ...
Loading model from cache /var/folders/56/qpw4f8jd6m5gdyr1w3x_gn300000gn/T/
jieba.cache
Loading model cost 0.389 seconds.
Prefix dict has been built successfully.
```

```
['今天', '是', '個', '好', '天氣', ' ', ' ', '我們', '一起', '去', '台北市立', '美術館', '!', '']
['自然', '語言', '處理', '在', '教育', '、', '醫療', '與', '金融', '領域', '都', '有', '泛', '應用', '。']
['請', '問', '下', '週三', '下午', '兩點', '在', 'BS440', '教室', '還有', '課', '嗎', '?']
['你', '覺得', '大型', '語言', '模型', '在', '中文', '任務上', '的', '表現', '如何', '?']
['他', '知道', '這件', '事', '不要', '緊']
['這份', '報告', '我', '寫', '不好']
['他', '有', '一個', '女兒', ' ', ' ', '在', '醫院', '工作']
['我', '在', '樓', '上', '看到', '了', '他']
['兒', '的', '生活', '好', '痛苦', '也', '沒', '有', '糧食', '多', '病少', '掙', '了', '多', '錢']
```

4. POS Tagging (詞性標註)

In [5]: `from jieba import posseg as pseg`

```
def pos_tag_zh(text: str):
    return [(w.word, w.flag) for w in pseg.cut(text)]

for s in SENTENCES_ZH:
    print(pos_tag_zh(s))
```

```
[('今天', 't'), ('是', 'v'), ('個', 'q'), ('好', 'a'), ('天氣', 'n'), (' ', 'x'), ('我們', 'r'), ('一起', 'm'), ('去', 'v'), ('台北市立', 'nt'), ('美術館', 'nt'), ('吧', 'y'), ('!', 'x')]
[('自然', 'd'), ('語言', 'n'), ('處理', 'v'), ('在', 'p'), ('教育', 'vn'), ('、', 'x'), ('醫療', 'n'), ('與', 'p'), ('金融', 'n'), ('領域', 'n'), ('都', 'd'), ('有', 'v'), ('廣泛', 'a'), ('應用', 'v'), ('。', 'x')]
[('請', 'v'), ('問', 'v'), ('下週', 't'), ('三', 'm'), ('下午', 't'), ('兩點', 'm'), ('在', 'p'), ('BS440', 'eng'), ('教室', 'n'), ('還', 'd'), ('有', 'v'), ('課', 'n'), ('嗎', 'y'), ('?', 'x')]
[('你', 'r'), ('覺得', 'v'), ('大型', 'b'), ('語言', 'n'), ('模型', 'n'), ('在', 'p'), ('中文', 'nz'), ('任務', 'n'), ('上', 'f'), ('的', 'uj'), ('表現', 'v'), ('如何', 'v'), ('?', 'x')]
[('他', 'r'), ('知道', 'v'), ('這件', 'mq'), ('事', 'n'), ('不要', 'df'), ('緊', 'n'), ('這份', 'mq'), ('報告', 'n'), ('我', 'r'), ('寫', 'v'), ('不好', 'd')]
[('他', 'r'), ('有', 'v'), ('一個', 'm'), ('女兒', 'n'), (' ', 'x'), ('在', 'p'), ('院', 'n'), ('工作', 'vn')]
[('我', 'r'), ('在', 'p'), ('樓上', 's'), ('看到', 'v'), ('了', 'ul'), ('他', 'r'), ('兒', 'n'), ('的', 'uj'), ('生活', 'vn'), ('好', 'a'), ('痛苦', 'an'), ('也', 'n'), ('沒有', 'v'), ('糧食', 'n'), ('多', 'm'), ('病', 'n'), ('少', 'a'), ('掙', 'v'), ('了', 'ul'), ('很多', 'm'), ('錢', 'x')]
```

5. Analysis: Frequency & POS Distribution

In [6]: `from collections import Counter`

```
all_tokens = []
all_pos = []
for s in SENTENCES_ZH:
    toks = tokenize_zh(s)
    all_tokens.extend(toks)
    all_pos.extend([p for _, p in pos_tag_zh(s)])

print('Top tokens:', Counter(all_tokens).most_common(10))
print('POS distribution:', Counter(all_pos).most_common())
```

Top tokens: [('在', 5), ('有', 3), ('他', 3), ('好', 2), (' ', 2), ('語言', 2), ('?', 2), ('的', 2), ('我', 2), ('了', 2)]
POS distribution: [('n', 17), ('v', 16), ('x', 9), ('r', 8), ('m', 6), ('p', 5), ('d', 5), ('a', 4), ('t', 3), ('vn', 3), ('nt', 2), ('y', 2), ('uj', 2), ('mq', 2), ('ul', 2), ('q', 1), ('eng', 1), ('b', 1), ('nz', 1), ('f', 1), ('df', 1), ('an', 1)]

6. 比較 jieba 與 spaCy 的斷詞結果

我先用上面的 sample code 跑完 jieba 的斷詞、POS tagging 和詞頻統計，確認都能正常執行後，spaCy 的 `zh_core_web_sm` 中文模型對同一批句子做比較，看看兩套工具在實際結果上有什麼

6.1 用 spaCy 跑同一批句子

```
In [7]: import spacy

nlp = spacy.load("zh_core_web_sm")

def tokenize_spacy(text: str):
    doc = nlp(text)
    return [tok.text for tok in doc if tok.text.strip()]

def pos_tag_spacy(text: str):
    doc = nlp(text)
    return [(tok.text, tok.pos_) for tok in doc if tok.text.strip()]

print("=== spaCy Tokenization ===")
for s in SENTENCES_ZH:
    print(tokenize_spacy(s))

print("\n=== spaCy POS Tagging ===")
for s in SENTENCES_ZH:
    print(pos_tag_spacy(s))
```

=== spaCy Tokenization ===

```
['今天', '是', '個好', '天氣', ',', ' ', '我', '們', '一起', '去', '台北市', '立美', '術館', '吧', '!', '']  
['自然', '語言', '處理', '在', '教育', '、', '醫療', '與', '金融', '領域', '都', '有', '泛', '應用', '。', '']  
['請問', '下週', '三', '下午', '兩點', '在', 'BS', '440', '教室', '還', '有', '課嗎', '?', '']  
['你', '覺', '得', '大型', '語言', '模型', '在', '中文', '任務', '上', '的', '表現', '何', '?', '']  
['他', '知道', '這件', '事', '不要', '緊']  
['這份', '報告', '我', '寫', '不', '好']  
['他', '有', '一', '個', '女兒', '，', '，', '在', '醫院', '工作']  
['我', '在', '樓上', '看到', '了', '他']  
['兒', '的', '生活', '好', '痛苦', '也', '沒有', '糧食', '多', '病少', '掙', '了', '很多', '錢']
```

=== spaCy POS Tagging ===

```
[('今天', 'NOUN'), ('是', 'VERB'), ('個好', 'NOUN'), ('天氣', 'VERB'), (',', 'PUNCT'), ('我', 'PRON'), ('們', 'VERB'), ('一起', 'ADV'), ('去', 'VERB'), ('台北', 'PROPN'), ('立美', 'VERB'), ('術館', 'VERB'), ('吧', 'PART'), ('!', 'PUNCT')]  
[('自然', 'ADV'), ('語言', 'VERB'), ('處理', 'VERB'), ('在', 'ADP'), ('教育', 'NOUN'), ('、', 'PUNCT'), ('醫療', 'NOUN'), ('與', 'VERB'), ('金融', 'NOUN'), ('領域', 'NOUN'), ('都', 'ADV'), ('有', 'VERB'), ('廣泛', 'NOUN'), ('應用', 'VERB'), ('。', 'PUNCT')]  
[('請問', 'VERB'), ('下週', 'NOUN'), ('三', 'NUM'), ('下午', 'NOUN'), ('兩點', 'NOUN'), ('在', 'ADP'), ('BS', 'PROPN'), ('440', 'NUM'), ('教室', 'NOUN'), ('還', 'VERB'), ('有', 'VERB'), ('課嗎', 'NOUN'), ('?', 'PUNCT')]  
[('你', 'PRON'), ('覺', 'VERB'), ('得', 'PART'), ('大型', 'ADJ'), ('語言', 'NOUN'), ('模型', 'NOUN'), ('在', 'ADP'), ('中文', 'NOUN'), ('任務', 'NOUN'), ('上', 'PART'), ('的', 'PART'), ('表現', 'NOUN'), ('如何', 'VERB'), ('?', 'PUNCT')]  
[('他', 'PRON'), ('知道', 'VERB'), ('這件', 'NOUN'), ('事', 'NOUN'), ('不要', 'ADV'), ('緊', 'VERB')]  
[('這份', 'NOUN'), ('報告', 'NOUN'), ('我', 'PRON'), ('寫', 'VERB'), ('不', 'ADV'), ('好', 'VERB')]  
[('他', 'PRON'), ('有', 'VERB'), ('一', 'NUM'), ('個', 'NUM'), ('女兒', 'NOUN'), ('，', 'PUNCT'), ('在', 'ADP'), ('醫院', 'PROPN'), ('工作', 'VERB')]  
[('我', 'PRON'), ('在', 'ADP'), ('樓上', 'NOUN'), ('看到', 'VERB'), ('了', 'PART'), ('他', 'PRON')]  
[('兒', 'NOUN'), ('的', 'PART'), ('生活', 'NOUN'), ('好', 'VERB'), ('痛苦', 'VERB'), ('也', 'ADV'), ('沒有', 'VERB'), ('糧食', 'NOUN'), ('多', 'ADV'), ('病少', 'NOUN'), ('掙', 'VERB'), ('了', 'PART'), ('很多', 'NUM'), ('錢', 'NUM')]
```

6.2 逐句比較斷詞結果

接下來把兩套工具的斷詞結果放在一起對照，比較容易看出差異在哪裡。

```
In [8]: print("=" * 80)  
print("jieba vs spaCy - 斷詞比較")  
print("=" * 80)  
  
for i, s in enumerate(SENTENCES_ZH):  
    jieba_toks = tokenize_zh(s)  
    spacy_toks = tokenize_spacy(s)  
    print(f"\n--- 句子 {i+1}: {s}")  
    print(f"    jieba ({len(jieba_toks)} tokens): {' / '.join(jieba_toks)}")  
    print(f"    spaCy ({len(spacy_toks)} tokens): {' / '.join(spacy_toks)}")  
  
    # 找出差異  
    if jieba_toks != spacy_toks:  
        jieba_set = set(jieba_toks)
```

```
spacy_set = set(spacy_toks)
only_jieba = jieba_set - spacy_set
only_spacy = spacy_set - jieba_set
if only_jieba:
    print(f" → jieba 獨有: {only_jieba}")
if only_spacy:
    print(f" → spaCy 獨有: {only_spacy}")
```

jieba vs spaCy – 斷詞比較

--- 句子 1: 今天是個好天氣, 我們一起去台北市立美術館吧!

jieba (13 tokens): 今天 / 是 / 個 / 好 / 天氣 / , / 我們 / 一起 / 去 / 台北市立 / 館 / 吧 / !

spaCy (14 tokens): 今天 / 是 / 個好 / 天氣 / , / 我 / 們 / 一起 / 去 / 台北市 / 立 / 術館 / 吧 / !

→ jieba 獨有: {'美術館', '我們', '個', '台北市立', '好'}

→ spaCy 獨有: {'個好', '我', '們', '台北市', '術館', '立美'}

--- 句子 2: 自然語言處理在教育、醫療與金融領域都有廣泛應用。

jieba (15 tokens): 自然 / 語言 / 處理 / 在 / 教育 / 、 / 醫療 / 與 / 金融 / 領域 / 有 / 廣泛 / 應用 / 。

spaCy (15 tokens): 自然 / 語言 / 處理 / 在 / 教育 / 、 / 醫療 / 與 / 金融 / 領域 / 有 / 廣泛 / 應用 / 。

--- 句子 3: 請問下週三下午兩點在BS440教室還有課嗎?

jieba (12 tokens): 請 / 問下 / 週三 / 下午 / 兩點 / 在 / BS440 / 教室 / 還有 / 課 / 嗎 / ?

spaCy (13 tokens): 請問 / 下週 / 三 / 下午 / 兩點 / 在 / BS / 440 / 教室 / 還 / 有 / 嗎 / ?

→ jieba 獨有: {'還有', '週三', '問下', '請', 'BS440', '課', '嗎'}

→ spaCy 獨有: {'有', '請問', '還', '440', '下週', 'BS', '課嗎', '三'}

--- 句子 4: 你覺得大型語言模型在中文任務上的表現如何?

jieba (12 tokens): 你 / 覺得 / 大型 / 語言 / 模型 / 在 / 中文 / 任務上 / 的 / 表現 / 何 / ?

spaCy (14 tokens): 你 / 覺 / 得 / 大型 / 語言 / 模型 / 在 / 中文 / 任務 / 上 / 的 / 現 / 如何 / ?

→ jieba 獨有: {'任務上', '覺得'}

→ spaCy 獨有: {'覺', '任務', '得', '上'}

--- 句子 5: 他知道這件事不要緊

jieba (6 tokens): 他 / 知道 / 這件 / 事 / 不要 / 緊

spaCy (6 tokens): 他 / 知道 / 這件 / 事 / 不要 / 緊

--- 句子 6: 這份報告我寫不好

jieba (5 tokens): 這份 / 報告 / 我 / 寫 / 不好

spaCy (6 tokens): 這份 / 報告 / 我 / 寫 / 不 / 好

→ jieba 獨有: {'不好'}

→ spaCy 獨有: {'好', '不'}

--- 句子 7: 他有一個女兒, 在醫院工作

jieba (8 tokens): 他 / 有 / 一個 / 女兒 / , / 在 / 醫院 / 工作

spaCy (9 tokens): 他 / 有 / 一 / 個 / 女兒 / , / 在 / 醫院 / 工作

→ jieba 獨有: {'一個'}

→ spaCy 獨有: {'一', '個'}

--- 句子 8: 我在樓上看到了他

jieba (7 tokens): 我 / 在 / 樓 / 上 / 看到 / 了 / 他

spaCy (6 tokens): 我 / 在 / 樓上 / 看到 / 了 / 他

→ jieba 獨有: {'樓', '上'}

→ spaCy 獨有: {'樓上'}

--- 句子 9: 兒的生活好痛苦也沒有糧食多病少掙了很多錢

jieba (15 tokens): 兒 / 的 / 生活 / 好 / 痛苦 / 也 / 沒 / 有 / 糧食 / 多 / 病少 / 了 / 很多 / 錢

spaCy (14 tokens): 兒 / 的 / 生活 / 好 / 痛苦 / 也 / 沒有 / 糧食 / 多 / 病少 / 掙

很多 / 錢

→ jieba 獨有: {'沒', '有'}

→ spaCy 獨有: {'沒有'}

6.3 詞性標註比較

兩套工具用的 POS 標籤系統完全不同, jieba 用北大標註集 (像 `n`, `v`, `r`), spaCy 用 Univer-
Tags (像 `NOUN`, `VERB`, `PRON`), 所以不能直接比標籤名稱, 但可以看各自標得合不合理。

```
In [9]: print("=" * 60)
print("jieba vs spaCy - 詞性標註比較")
print("=" * 60)

for i, s in enumerate(SENTENCES_ZH):
    jieba_pos = pos_tag_zh(s)
    spacy_pos = pos_tag_spacy(s)
    print(f"\n--- 句子 {i+1}: {s}")
    print(f"    jieba : {jieba_pos}")
    print(f"    spaCy : {spacy_pos}")
```

```
=====
jieba vs spaCy - 詞性標註比較
=====
```

--- 句子 1: 今天是個好天氣, 我們一起去台北市立美術館吧!

jieba : [('今天', 't'), ('是', 'v'), ('個', 'q'), ('好', 'a'), ('天氣', 'n'),
'x'), ('我們', 'r'), ('一起', 'm'), ('去', 'v'), ('台北市立', 'nt'), ('美術館', 'n'
'吧', 'y'), ('!', 'x')]

spaCy : [('今天', 'NOUN'), ('是', 'VERB'), ('個好', 'NOUN'), ('天氣', 'VERB'),
(',', 'PUNCT'), ('我', 'PRON'), ('們', 'VERB'), ('一起', 'ADV'), ('去', 'VERB')
北市', 'PROPN'), ('立美', 'VERB'), ('術館', 'VERB'), ('吧', 'PART'), ('!', 'PUNCT')]

--- 句子 2: 自然語言處理在教育、醫療與金融領域都有廣泛應用。

jieba : [('自然', 'd'), ('語言', 'n'), ('處理', 'v'), ('在', 'p'), ('教育', 'vn'
'、', 'x'), ('醫療', 'n'), ('與', 'p'), ('金融', 'n'), ('領域', 'n'), ('都', 'd'
'有', 'v'), ('廣泛', 'a'), ('應用', 'v'), ('。', 'x')]

spaCy : [('自然', 'ADV'), ('語言', 'VERB'), ('處理', 'VERB'), ('在', 'ADP'), ('
'NOUN'), ('、', 'PUNCT'), ('醫療', 'NOUN'), ('與', 'VERB'), ('金融', 'NOUN'), ('
'NOUN'), ('都', 'ADV'), ('有', 'VERB'), ('廣泛', 'NOUN'), ('應用', 'VERB'), ('。
'PUNCT')]

—— 句子 3：請問下週三下午兩點在BS440教室還有課嗎？

```
jieba : [('請', 'v'), ('問', 'v'), ('下週', 't'), ('三', 'm'), ('下午', 't'), ('點', 'm'), ('在', 'p'), ('BS440', 'eng'), ('教室', 'n'), ('還', 'd'), ('有', 'v'), ('課', 'n'), ('嗎', 'y'), ('?', 'x')]
```

```
spaCy : [('請問', 'VERB'), ('下週', 'NOUN'), ('三', 'NUM'), ('下午', 'NOUN'), ('點', 'VERB'), ('在', 'ADP'), ('BS', 'PROPN'), ('440', 'NUM'), ('教室', 'NOUN'), ('還', 'VERB'), ('有', 'VERB'), ('課嗎', 'NOUN'), ('?', 'PUNCT')]
```

—— 句子 4：你覺得大型語言模型在中文任務上的表現如何？

```
jieba : [('你', 'r'), ('覺得', 'v'), ('大型', 'b'), ('語言', 'n'), ('模型', 'n'), ('在', 'p'), ('中文', 'nz'), ('任務', 'n'), ('上', 'f'), ('的', 'uj'), ('表現', 'v'), ('如何', 'r'), ('?', 'x')]
```

```
spaCy : [('你', 'PRON'), ('覺', 'VERB'), ('得', 'PART'), ('大型', 'ADJ'), ('語', 'NOUN'), ('模型', 'NOUN'), ('在', 'ADP'), ('中文', 'NOUN'), ('任務', 'NOUN'), ('上', 'PART'), ('的', 'PART'), ('表現', 'NOUN'), ('如何', 'VERB'), ('?', 'PUNCT')]
```

—— 句子 5：他知道這件事不要緊

```
jieba : [('他', 'r'), ('知道', 'v'), ('這件', 'mq'), ('事', 'n'), ('不要', 'df'), ('緊', 'x')]
```

```
spaCy : [('他', 'PRON'), ('知道', 'VERB'), ('這件', 'NOUN'), ('事', 'NOUN'), ('要', 'ADV'), ('緊', 'VERB')]
```

—— 句子 6：這份報告我寫不好

```
jieba : [('這份', 'mq'), ('報告', 'n'), ('我', 'r'), ('寫', 'v'), ('不好', 'd')]
```

```
spaCy : [('這份', 'NOUN'), ('報告', 'NOUN'), ('我', 'PRON'), ('寫', 'VERB'), ('好', 'ADV'), ('好', 'VERB')]
```

—— 句子 7：他有一個女兒，在醫院工作

```
jieba : [('他', 'r'), ('有', 'v'), ('一個', 'm'), ('女兒', 'n'), ('，', 'x'), ('在', 'p'), ('醫院', 'n'), ('工作', 'vn')]
```

```
spaCy : [('他', 'PRON'), ('有', 'VERB'), ('一', 'NUM'), ('個', 'NUM'), ('女兒', 'NOUN'), ('，', 'PUNCT'), ('在', 'ADP'), ('醫院', 'PROPN'), ('工作', 'VERB')]
```

—— 句子 8：我在樓上看到了他

```
jieba : [('我', 'r'), ('在', 'p'), ('樓上', 's'), ('看到', 'v'), ('了', 'ul'), ('他', 'r')]
```

```
spaCy : [('我', 'PRON'), ('在', 'ADP'), ('樓上', 'NOUN'), ('看到', 'VERB'), ('了', 'PART'), ('他', 'PRON')]
```

—— 句子 9：兒的生活好痛苦也沒有糧食多病少掙了很多錢

```
jieba : [('兒', 'n'), ('的', 'uj'), ('生活', 'vn'), ('好', 'a'), ('痛苦', 'an'), ('也', 'd'), ('沒有', 'v'), ('糧食', 'n'), ('多', 'm'), ('病', 'n'), ('少', 'a'), ('掙', 'v'), ('了', 'ul'), ('很多', 'm'), ('錢', 'x')]
```

```
spaCy : [('兒', 'NOUN'), ('的', 'PART'), ('生活', 'NOUN'), ('好', 'VERB'), ('也', 'VERB'), ('也', 'ADV'), ('沒有', 'VERB'), ('糧食', 'NOUN'), ('多', 'ADV'), ('病少', 'NOUN'), ('掙', 'VERB'), ('了', 'PART'), ('很多', 'NUM'), ('錢', 'NUM')]
```

6.4 觀察與分析

跑完之後我覺得蠻意外的，一開始以為 spaCy 用了深度學習模型應該會比 jieba 穩，但實際上在這句子裡，spaCy 的斷詞反而切得比較碎、比較不自然。以下挑幾個差異比較明顯的例子來討論，把兩套工具結果差不多就不展開了。

例子 1：「今天是個好天氣，我們一起去台北市立美術館吧！」

• jieba：台北市立 / 美術館 → 雖然沒有完整保留「台北市立美術館」，但至少還看得出是一

- spaCy：「**台北市 / 立美 / 術館**」→「立美」「術館」完全不是詞，切得很離譜
- 另外 spaCy 還把「個好」黏在一起，把「我們」拆成「我 / 們」，這些都不太合理

在專有名詞的處理上，jieba 明顯比 spaCy 好很多。

例子 2：「請問下週三下午兩點在BS440教室還有課嗎？」

- jieba：把「BS440」當成一個詞，但出現了「問下」這種不自然的組合
 - spaCy：把「BS440」拆成「BS / 440」，然後「課嗎」黏在一起
 - 兩套工具都沒辦法完美處理這種中英數混合的句子，各有各的問題
-

例子 3：「這份報告我寫不好」

- jieba：「**寫 / 不好**」→把「不好」留在一起，語意比較完整
- spaCy：「**寫 / 不 / 好**」→拆成三個，失去了「寫不好」作為補語結構的語意

這個差異蠻有趣的，顯示不同工具對中文否定結構、補語的處理邏輯不太一樣。

例子 4：「他知道這件事不要緊」

- jieba 和 spaCy 都把「不要緊」切成「不要 / 緊」
 - 但「不要緊」其實是固定用法（意思是「沒關係」），理想上應該保留為一個詞
 - 這代表純詞典式或預設模型的斷詞，碰到慣用語時不一定切得對
-

另外值得注意的是，這批 sample data 裡有幾句本身就帶有歧義，像是「他知道這件事不要緊」「告我寫不好」「我在樓上看到了他」「兒的生活好痛苦也沒有糧食多病少掙了很多錢」。這些句子詞位置不同，可能會產生不同的語意理解。例如最後一句完全沒有標點，讓兩套工具都很難處理，「少」這種切法就明顯不對。

整體來看：在這次測試中，jieba 的斷詞結果比 spaCy 更接近日常中文的使用習慣，spaCy 雖然學習模型，但 `zh_core_web_sm` 是比較小的模型，在繁體中文上的表現不太理想。不過兩套工具專有名詞、口語固定搭配、歧義句或中英混合文字時，都還是需要人工確認結果。

7. Reflection

這次作業讓我比較深刻感受到中文 NLP 前處理跟英文真的差很多。英文有空格天然分隔，但中文果會直接影響後面的 POS tagging 和詞頻統計——前面切錯了，後面分析也會跟著歪掉。

像「台北市立美術館」這種專有名詞，或「不要緊」這種固定搭配，目前的工具都沒辦法完美處理。有些 sample data 裡的句子本身就具有歧義（像「我在樓上看到了他」到底是「我在樓上」還是「他上」），這種情況下不管用什麼工具斷詞，都很難保證結果是正確的，還是需要人自己判斷。

另外我原本以為 spaCy 一定比 jieba 強，但實際測試發現它的小模型（`zh_core_web_sm`）在：上表現並不好，反而 jieba 雖然只是基於詞典的統計方法，在多數情況下結果更合理。這讓我覺得不能只看「技術比較新」，還是要看實際跑出來的結果。